

Programa de investigación conjunta (informe rápido)

Random Matrix Theory y Genómica Computacional
Propuesta de colaboración con el Dr. Enrique Hernández-Lemus

Septiembre de 2026

Resumen ejecutivo

Se propone un programa de investigación conjunta que use *Random Matrix Theory* (RMT) — estática (ensambles, umbrales espectrales) y dinámica (movimiento browniano de Dyson, repulsión de niveles) — junto con análisis multiescala por *wavelets*, como marco matemático para problemas actuales de genómica computacional y oncología de sistemas, con foco en cáncer de mama. La idea central es modelar la frontera entre *señal biológica estructurada* y *ruido de alta dimensión* en matrices derivadas de datos multi-ómicos, redes de coexpresión a gran escala, matrices de contacto cromatínico tipo Hi-C y datos de célula única, y validar esa frontera con protocolos numéricos explícitos y reproducibles sobre datos públicos reales. La propuesta está alineada con la trayectoria reciente del Dr. Enrique Hernández-Lemus en integración multi-ómica en cáncer, redes regulatorias multicapa, genómica 3D y redes específicas por paciente.

1. Justificación científica

El Dr. Enrique Hernández-Lemus dirige el Laboratorio de Biología Computacional de Sistemas y Genómica Integrativa del Departamento de Genómica Computacional del INMEGEN, con trabajo reciente en integración de datos multi-ómicos en cáncer [4], redes regulatorias multicapa [5], estructura de *k-cores* en redes de cáncer de mama [6], conformación cromosómica en cáncer de mama triple negativo [7] y redes de coexpresión específicas por paciente [8]. Estas líneas sugieren un contexto ideal para introducir herramientas espectrales rigurosas — estáticas y dinámicas — de RMT sobre matrices de covarianza, correlación, afinidad y contacto cromatínico [1, 3, 7, 8].

Desde el punto de vista metodológico, RMT ofrece una ventaja estratégica: permite construir *ensambles nulos* y umbrales espectrales no ad hoc para distinguir estructura biológica real frente a artefactos debidos a alta dimensionalidad, escasez muestral, heterocedasticidad y sparsidad. El método fundacional de Luo et al. [12], ya validado a gran escala [13] y extendido a redes de interacción génica en cáncer [14], usa precisamente la transición de la distribución de espaciamientos entre vecinos más cercanos (NNSD), de Poisson a la estadística de Wigner-Dyson del ensamble ortogonal gaussiano (GOE), para fijar un umbral de correlación no arbitrario en redes de coexpresión — exactamente el tipo de red a gran escala (*big scale networks*) que el grupo del Dr. Hernández-Lemus ya construye. Esta lógica ya ha mostrado utilidad en análisis de célula única, donde existen trabajos de denoising guiado por RMT y métodos espectrales para extraer señal de matrices extremadamente ruidosas [9, 10]. Asimismo, en Hi-C reciente se ha señalado que ciertos

esquemas de suavizado por random walks deben tratarse con cautela, lo cual abre espacio para null models espectrales mejor fundamentados [11].

2. Hipótesis rectora

La hipótesis del programa es la siguiente:

La estructura biológica relevante puede detectarse y cuantificarse como desviación espectral robusta — estática y dinámica — respecto de un ensamble nulo de alta dimensión, y esa desviación es numéricamente validable sobre cohortes independientes.

Dicho de otro modo, autovalores salientes, autovectores localizados, estadísticos lineales de eigenvalores, rupturas universales del *bulk*, y patrones de repulsión/casi-colisión entre autovalores bajo perturbación o evolución temporal, pueden funcionar como marcadores matemáticamente controlados de modularidad funcional, heterogeneidad tumoral, reorganización cromatínica y señal paciente-específica — siempre que la desviación sobreviva a un protocolo explícito de validación estadística.

3. Objetivo general

Desarrollar una agenda conjunta de investigación que integre Random Matrix Theory (estática y dinámica), análisis multiescala por wavelets, teoría espectral de redes, y aprendizaje automático, con datos reales de genómica computacional, con énfasis en cáncer de mama, multi-ómica, genómica 3D, célula única y redes a gran escala, y con un protocolo de validación numérica explícito en cada línea.

4. Objetivos específicos

1. Construir modelos nulos espectrales para matrices de expresión, coexpresión y covarianza multi-ómica, a la escala de redes completas del transcriptoma ($p \sim 10^4$ – 10^5).
2. Diseñar criterios RMT — estáticos (NNSD, IPR) y dinámicos (Dyson, repulsión de niveles) — para detección de módulos biológicos, subtipos tumorales y biomarcadores robustos.
3. Extender el marco a matrices de contacto cromatínico (Hi-C/scHi-C) y redes multicapa expresión-conformación, incorporando descomposición *wavelet* multiescala como paso de pre-procesamiento y de extracción de características.
4. Desarrollar variantes para redes específicas por paciente y para datos de célula única de alta sparsidad, y acoplarlas a clasificadores de aprendizaje automático cuyo propio proceso de entrenamiento se analice con las mismas herramientas espectrales (reconocimiento de subtipo/patrón).
5. Fijar, para cada línea, un protocolo de validación (remuestreo, cohortes independientes, control de falsos positivos) y traducir estos desarrollos a *pipelines* computacionales reproducibles y a artículos de metodología aplicada.

5. Líneas de trabajo propuestas

5.1. Línea 1. Denoising espectral y detección de señal en datos multi-ómicos

Sea $X \in \mathbb{R}^{p \times n}$ una matriz de datos ómicos centrada y escalada, con p variables y n muestras. La matriz

$$S = \frac{1}{n} X X^\top$$

puede interpretarse como matriz de covarianza o correlación empírica. El primer objetivo es estudiar el espectro de S frente a ensambles nulos apropiados (Wishart, spiked models, variantes heterocedásticas o con ruido correlacionado), para separar:

- **bulk espectral:** parte compatible con ruido de alta dimensión, delimitada por la ley de Marchenko–Pastur;
- **outliers:** componentes compatibles con señal biológica organizada;
- **localización de autovectores:** firmas de módulos génicos o ejes tumorales, cuantificadas por el *inverse participation ratio* (IPR).

Meta concreta. Desarrollar un método de filtrado espectral para matrices multi-ómicas y comparar su desempeño con PCA estándar, sparse PCA y enfoques de redes usados en la literatura reciente de integración multi-ómica [3, 4].

5.2. Línea 2. RMT para redes de coexpresión a gran escala y biomarcadores específicos por paciente

Los trabajos recientes sobre redes específicas por paciente muestran que la estructura regulatoria individualizada puede revelar subtipos y biomarcadores no visibles en redes promedio [8], y que la estructura de *k-cores* organiza jerárquicamente las redes de cáncer de mama [6]. El método de umbral espectral de Luo et al. [12], ya usado a la escala de redes completas del transcriptoma [13], es el punto de partida natural para redes de este tamaño. Aquí la contribución conjunta puede ser fuerte: pasar de una red inferida empíricamente a una teoría de *significancia espectral* de esa red, y de ahí a una noción cuantitativa de qué tan robusto es un *k-core* o un módulo bajo la incertidumbre estadística que el propio umbral espectral hace explícita.

Problemas propuestos:

- (a) estudiar espectros de matrices de adyacencia o Laplacianos de redes de coexpresión a gran escala bajo null models dependientes del grado y de la distribución empírica;
- (b) definir estadísticos basados en la separación de autovalores y en la localización de autovectores para clasificar pacientes;
- (c) construir indicadores de estabilidad espectral de biomarcadores y de *k-cores* bajo remuestreo y perturbaciones.

Meta concreta. Producir un artículo metodológico sobre *RMT for patient-specific regulatory networks*, con aplicación a cáncer de mama.

5.3. Línea 3. Modelos espectrales para Hi-C y genómica 3D

La integración entre conformación cromosómica y expresión génica ya es una línea activa en el grupo del Dr. Hernández-Lemus, particularmente en cáncer de mama triple negativo [7]. Aquí RMT puede aportar una base matemática novedosa para matrices de contacto, kernels de proximidad y operadores derivados de Hi-C.

Preguntas clave:

- ¿Qué parte del espectro de una matriz de contacto cromatínico corresponde a arquitectura robusta y cuál a ruido experimental o a profundidad de secuenciación?
- ¿Cómo definir ensambles nulos que respeten sesgos marginales, dependencia con la distancia genómica y sparsidad?
- ¿Qué estadísticos espectrales detectan reordenamientos estructurales en tumores frente a tejido normal?

Meta concreta. Desarrollar una teoría preliminar de *spectral null models for chromatin contact matrices* y aplicarla a datos TNBC. Esto conectaría de manera directa con el trabajo reciente del grupo y le daría una capa matemática diferenciadora.

5.4. Línea 4. RMT en célula única y multimodalidad

El análisis de célula única y topología de datos ya aparece como área de expansión natural del grupo [2, 10]. Los datos scRNA-seq y multiome presentan precisamente el régimen donde RMT es más valiosa: gran dimensión, matrices esparsas, ruido técnico elevado y señal de baja jerarquía.

Metas concretas:

- (a) adaptar técnicas de denoising RMT a scRNA-seq y scATAC/scRNA integrados;
- (b) usar umbrales Tracy–Widom o pruebas tipo Marchenko–Pastur para selección de componentes informativos;
- (c) estudiar el acoplamiento entre RMT y métodos topológicos, usando los objetos espectralmente depurados como entrada para TDA o clustering jerárquico.

5.5. Línea 5. Análisis multiescala por wavelets

Las redes de coexpresión y las matrices de contacto Hi-C tienen estructura a múltiples escalas simultáneas: módulos génicos locales, dominios topológicamente asociados (TADs) de tamaño intermedio, y compartimentos A/B de gran escala. Un umbral espectral único, aplicado a la matriz completa, puede ser demasiado grueso para separar señal a todas estas escalas a la vez. König et al. [15] ya mostraron, sobre la red metabólica de *E. coli*, que una transformada wavelet aplicada a los perfiles de expresión — y a las matrices de adyacencia de los clusters resultantes — extrae patrones funcionales que un análisis de escala única no separa limpiamente.

Propuesta concreta. Antes de aplicar el umbral RMT de la Línea 2, descomponer la matriz de correlación (o la señal de contacto Hi-C a lo largo de la distancia genómica) en una jerarquía de

escalas mediante una transformada wavelet 2D discreta, y aplicar el criterio NNSD/Marchenko–Pastur *por escala*: la hipótesis de trabajo es que el nivel de escala en el que primero aparece una transición Poisson $\rightarrow$ Wigner-Dyson identifica la escala característica de la organización modular real (génica, TAD, o compartimento), en vez de imponerla a priori.

Meta concreta. Un método reproducible de *umbral espectral multiescala*, comparado contra el umbral de escala única de Luo et al. [12] sobre las mismas cohortes.

5.6. Línea 6. Dinámica de Dyson, repulsión de niveles, y reconocimiento

Todo lo anterior es *estático*: se calcula el espectro de una matriz fija. Dyson [16] mostró que, si las entradas de una matriz aleatoria evolucionan por difusión browniana, sus autovalores evolucionan como un gas de Coulomb unidimensional: cada par de autovalores se repele con fuerza $1/(\lambda_i - \lambda_j)$, de modo que dos autovalores casi nunca colisionan (*level repulsion*, la misma repulsión que produce la estadística de Wigner-Dyson en el caso estático). Esto sugiere dos extensiones concretas, ninguna de las dos presente en las Líneas 1–4:

- (a) **Dinámica sobre cohortes/tiempo.** Cuando la matriz de coexpresión o de contacto cromatínico se recalcula a lo largo de una progresión (estadios tumorales, pseudotiempo en célula única, o remuestreo secuencial de una cohorte), la trayectoria de cada autovalor puede tratarse como una realización de un proceso tipo Dyson. Una *casi-colisión* entre dos autovalores — un mínimo local pronunciado de $|\lambda_i - \lambda_j|$ — es candidata natural a marcar una transición estructural (p.ej. una reorganización modular o un cambio de subtipo), de forma análoga a como el mismo fenómeno se usa para detectar transiciones espectrales en otros sistemas físicos.
- (b) **Dinámica del propio reconecedor.** Aarts, Hajizadeh, Lucini y Park [17] muestran, para redes neuronales entrenadas por descenso de gradiente estocástico, que el espectro de las matrices de pesos evoluciona — desde una distribución inicial tipo Marchenko–Pastur hacia un gas de Coulomb con potencial dependiente del modelo — exactamente como movimiento browniano de Dyson, con el nivel de estocasticidad fijado por la razón entre tasa de aprendizaje y tamaño de minibatch. Esto da un lenguaje espectral *común* para los datos (Líneas 1–3) y para el clasificador de reconocimiento de subtipo/patrón que se entrena sobre ellos (Línea 4): en ambos casos, la pregunta de si la estructura aprendida es señal genuina o artefacto de optimización se plantea, literalmente, en los mismos términos de repulsión de autovalores.

Meta concreta. Una nota metodológica — *Dyson dynamics for spectral transitions in cancer genomics* — que formalice (a) sobre redes de coexpresión a través de estadios TNBC, y (b) sobre la dinámica de entrenamiento de un clasificador de subtipo entrenado sobre las mismas redes, verificando si ambas trayectorias muestran el mismo régimen de repulsión.

6. Validación y numérica

Cada línea anterior produce un umbral, un estadístico, o una trayectoria espectral; ninguno se reporta sin un protocolo de validación explícito:

1. **Ensamble nulo correcto.** Comparación contra Wishart puro *y* contra nulos que preservan momentos empíricos (grado, varianza marginal, sparsidad) — un umbral que sólo supera al Wishart puro no basta.
2. **Remuestreo.** Bootstrap y submuestreo de pacientes para reportar un intervalo, no un único valor, para cada autovalor saliente y cada estadístico de localización (IPR).
3. **Cohortes independientes.** Todo umbral o módulo detectado en una cohorte (p. ej. TCGA-BRCA) se reevalúa, sin reajustar parámetros, en al menos una cohorte independiente (p. ej. METABRIC o un GSE específico de TNBC); ver §8.
4. **Control de falsos positivos.** Corrección explícita por comparaciones múltiples al reportar módulos, biomarcadores o transiciones de Dyson candidatas.
5. **Numérica de referencia.** Un script de referencia (Python/NumPy/SciPy) que calcule, sobre datos sintéticos con espectro conocido, el umbral NNSD, la ley de Marchenko–Pastur teórica y el IPR, como prueba de correctitud antes de aplicar el método a datos reales; ver `scripts/` en el repositorio de este programa.

7. Núcleo matemático del programa

El programa puede organizarse alrededor de seis bloques teóricos:

1. ensambles de Wishart y leyes tipo Marchenko–Pastur;
2. modelos *spiked* y transición BBP para señal de bajo rango;
3. estadísticos lineales de eigenvalores y fluctuaciones tipo Tracy–Widom;
4. localización/delocalización de autovectores y robustez frente a ruido estructurado;
5. matrices aleatorias sobre grafos y operadores espectrales en redes multicapa a gran escala;
6. movimiento browniano de Dyson, repulsión de niveles, y análisis multiescala por wavelets como pre-procesamiento espectral.

Esto permite una división natural del trabajo: una parte más teórica (RMT, límites, umbrales, null models, dinámica de Dyson) y otra parte aplicada (pipelines, validación sobre cohortes, interpretación biológica, contraste con estado del arte).

8. Datos

Conjuntos de datos públicos, ya identificados, suficientes para arrancar las Líneas 1–2 y 5–6 sin esperar datos propios del grupo; ver `data/README.md` en el repositorio de este programa para instrucciones de descarga y notas de preprocesamiento.

- **GSE171958** (GEO) — metilación de DNA y RNA-seq para TNBC, con proteómica pareada en ProteomeXchange PXD025238; líneas celulares MCF10A, MDA-MB-231, HCC1937 [18]. Punto de entrada natural para la Línea 1 (denoising multi-ómico) y la Línea 5 (wavelets).

- **GSE176078** (GEO) — scRNA-seq de tumores de 10 pacientes con TNBC [19]. Punto de entrada para la Línea 4 (célula única) y la parte (a) de la Línea 6 (dinámica a través de pacientes/pseudotiempo).
- **TCGA-BRCA** — cohorte pública de referencia (expresión, metilación, mutación, clínico) para cáncer de mama; usada aquí como cohorte primaria de validación cruzada (§6, punto 3).
- **METABRIC** — cohorte pública independiente de TCGA-BRCA, con subtipificación clínica; cohorte de validación cruzada secundaria.

Ningún dato clínico o multi-ómico propio del grupo del Dr. Hernández-Lemus se asume ni se solicita aquí; estos cuatro conjuntos son de acceso público y bastan para un primer ciclo completo de desarrollo y validación metodológica.

9. Productos esperados

1. **Paper 1:** RMT para filtrado espectral en datos multi-ómicos de cáncer.
2. **Paper 2:** significancia espectral en redes específicas por paciente, a gran escala.
3. **Paper 3:** null models espectrales para matrices Hi-C y redes multicapa expresión–cromatina, con umbral multiescala por wavelets.
4. **Paper 4:** dinámica de Dyson y repulsión de niveles como marcador de transición estructural, con el paralelo dato/clasificador de la Línea 6.
5. **Software:** paquete reproducible en Python/R para análisis espectral estático y dinámico de datos genómicos, con protocolo de validación integrado.
6. **Seminario conjunto:** puente entre matemáticas, física estadística y genómica computacional.

10. Ruta tentativa de 12–18 meses

Fase I (0–4 meses)

Curación de los datasets de §8, revisión técnica conjunta, y desarrollo del primer pipeline RMT (Línea 1–2) con el protocolo de validación de §6 desde el inicio.

Fase II (4–9 meses)

Aplicación a redes específicas por paciente a gran escala (Línea 2) y elaboración del primer manuscrito metodológico. Paralelamente, diseño de null models multiescala para Hi-C (Líneas 3 y 5).

Fase III (9–14 meses)

Aplicación a TNBC con datos de conformación cromosómica y expresión (GSE171958, GSE176078); formulación del segundo y tercer artículos. Primera prueba de la dinámica de Dyson (Línea 6a).

Fase IV (14–18 meses)

Extensión a célula única, prueba de la dinámica de Dyson sobre el propio clasificador (Línea 6b), y consolidación de software, seminarios y siguiente agenda de financiamiento.

11. Ventaja estratégica de la colaboración

La colaboración tendría una identidad muy clara: no sería una aplicación superficial de técnicas matemáticas a datos biológicos, sino la construcción de un marco riguroso — estático y dinámico, de escala única y multiescala — para *inferencia espectral en genómica de alta dimensión*, con un protocolo de validación explícito en cada paso. El valor agregado para ambas partes es nítido:

- para el grupo del Dr. Hernández-Lemus, aporta una capa matemática fuerte, original y publicable, directamente sobre sus propias líneas de redes a gran escala, TNBC y multi-ómica;
- para la parte matemática, ofrece problemas reales, datasets complejos ya identificados (§8), y una ruta natural hacia publicaciones interdisciplinarias de alto nivel.

12. Primeros pasos sugeridos

1. Definir el caso de estudio inicial: TNBC, usando GSE171958 y GSE176078 (§8) como punto de partida inmediato, sin esperar datos propios.
2. Correr el script de referencia de §6 (`scripts/`) sobre datos sintéticos, y luego sobre una submuestra real, como prueba de concepto conjunta.
3. Escribir una nota conceptual de 2–3 páginas con una pregunta piloto y la metodología RMT mínima.
4. Preparar un seminario interno de arranque con lenguaje puente entre genómica y teoría espectral.

Conclusión

La colaboración propuesta tiene potencial real para convertirse en una línea estable de investigación. Su fuerza está en que conecta de manera orgánica el trabajo actual del Dr. Enrique Hernández-Lemus con una agenda matemática distintiva: RMT — estática y dinámica — como teoría de señal, ruido, estructura y robustez en sistemas genómicos complejos, complementada por análisis multiescala y por un protocolo de validación explícito desde el primer día. Bien planteada,

esta agenda puede producir resultados conceptuales, metodológicos y computacionales con salida natural hacia bioinformática matemática, biología de sistemas y oncología computacional.

Referencias

- [1] INMEGEN, *Dr. Enrique Hernández Lemus*, perfil institucional, Instituto Nacional de Medicina Genómica. <https://www.inmegen.gob.mx/investigacion/investigadores/curriculum-vitae/?perfil=59>
- [2] CSB-IG Group, *About Enrique Hernández-Lemus*. <https://csbig.inmegen.gob.mx/about/>
- [3] E. Hernández-Lemus y S. Ochoa, “Methods for multi-omic data integration in cancer research,” *Frontiers in Genetics*, 2024. <https://www.frontiersin.org/journals/genetics/articles/10.3389/fgene.2024.1425456/full>
- [4] Grupo Hernández-Lemus, “Functional impact of multi-omic interactions in breast cancer subtypes,” *Frontiers in Genetics*, 2022.
- [5] Grupo Hernández-Lemus, “An Information Theoretical Multilayer Network Approach to Breast Cancer Transcriptional Regulation,” *Frontiers in Genetics*, 2021.
- [6] Grupo Hernández-Lemus, “k-core genes underpin structural features of breast cancer,” *Scientific Reports*, 2021.
- [7] H. Reyes-Gopar, K. A. Pérez-Fuentes, M. L. Bendall y E. Hernández-Lemus, “Integration of chromosome conformation and gene expression networks reveals regulatory mechanisms in triple negative breast cancer,” *Frontiers in Cell and Developmental Biology*, 2025. <https://www.frontiersin.org/journals/cell-and-developmental-biology/articles/10.3389/fcell.2025.1597245/full>
- [8] P. López-Sánchez, F. Ávila-Moreno, E. Hernández-Lemus, M. L. Kuijjer y J. Espinal-Enríquez, “Patient-specific gene co-expression networks reveal novel subtypes and predictive biomarkers in lung adenocarcinoma,” *npj Systems Biology and Applications*, 2025. <https://www.nature.com/articles/s41540-025-00522-0>
- [9] L. Aparicio, K. Bordyuh, A. Blumberg y S. Levit, “A Random Matrix Theory Approach to Denoise Single-Cell Data,” *Patterns*, 2020. <https://pmc.ncbi.nlm.nih.gov/articles/PMC7660363/>
- [10] S. Levyang et al., “Revealing lineage-related signals in single-cell gene expression using random matrix theory,” *PNAS*, 2021. <https://www.pnas.org/doi/10.1073/pnas.1913931118>
- [11] Y. Liu et al., “Can random walking on a Hi-C contact matrix lead to data quality improvement?,” 2025. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12456815/>
- [12] F. Luo, Y. Yang, J. Zhong, H. Gao, L. Khan, D. K. Thompson y J. Zhou, “Constructing gene co-expression networks and predicting functions of unknown genes by random matrix theory,” *BMC Bioinformatics* **8**, 299 (2007). <https://doi.org/10.1186/1471-2105-8-299>
- [13] Massive-scale gene co-expression network construction and robustness testing using random matrix theory, *PLOS ONE*, 2012. <https://doi.org/10.1371/journal.pone.0055871>

- [14] Random matrix analysis for gene interaction networks in cancer cells, *Scientific Reports* **8** (2018). <https://doi.org/10.1038/s41598-018-28954-1>
- [15] R. König, G. Schramm, M. Oswald et al., “Discovering functional gene expression patterns in the metabolic network of Escherichia coli with wavelets transforms,” *BMC Bioinformatics* **7**, 119 (2006). <https://doi.org/10.1186/1471-2105-7-119>
- [16] F. J. Dyson, “A Brownian-Motion Model for the Eigenvalues of a Random Matrix,” *Journal of Mathematical Physics* **3**, 1191–1198 (1962).
- [17] G. Aarts, O. Hajizadeh, B. Lucini y C. Park, “Dyson Brownian motion and random matrix dynamics of weight matrices during learning,” preprint, arXiv:2411.13512, 2024. NeurIPS 2024 Workshop on Machine Learning and the Physical Sciences. <https://arxiv.org/abs/2411.13512>
- [18] Multi-omics data integration reveals correlated regulatory features of triple negative breast cancer, *Molecular Omics*, 2021. Data: GEO GSE171958, ProteomeXchange PXD025238. <https://doi.org/10.1039/D1M000117E>
- [19] Single-cell RNA-seq of triple negative breast cancer tumors (10 patients), GEO accession GSE176078. <https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE176078>